Progetto Modulo 2

Modulo 2 · Lezione 15



Dodici lezioni, un’unica pipeline

Oggi le dodici lezioni si mettono in fila, su un corpus scelto da ciascuno di voi: nessun concetto nuovo, solo integrazione.

loaders	clean	embeddings
search	vector DB	chunking
RAG	structured output	estrazione



Agenda

	Blocco	Dove si lavora	Tempo
	Brief progetto: pipeline, aikit, corpus, rubrica	slide	25′
	Build: i 4 TODO sul proprio corpus	`working/app.py`	170′
	Demo & valutazione	stesso file	45′

Nessun live coding oggi: il docente gira tra i banchi durante Build e Demo.



Lo schema della pipeline completa



Risposta strutturata

Pattern di Modulo 2 · Lezione 13, applicato all'ultimo blocco: `generate` restituisce un oggetto, non testo libero.

Estrazione fatture

Pattern di Modulo 2 · Lezione 14, su un dataset a sé (le fatture Lumen) — indipendente dal corpus indicizzato.

aikit completo: tornano loaders e clean

`aikit/` ha sette moduli in tutto. Oggi ne richiamiamo **cinque**: `chunk`, `embeddings`, `vectorstore` non hanno mai smesso di servire. `loaders` (Modulo 2 · Lezione 4) e `clean` (Modulo 2 · Lezione 5) tornano dopo un mese di pausa: il corpus non arriva più già pulito da uno script.

Non si riscrivono, si importano tali e quali — come sempre in `aikit/`.

> Gli altri due, `llm_client` e `aikit.search`, restano nel toolkit ma non servono oggi: structured outputs usa il client OpenAI diretto, la ricerca reale passa dal vector DB da Modulo 2 · Lezione 9 in poi.



Il corpus: libero, con una riserva

`il vostro`

3–10 file propri

PDF / DOCX / HTML / Markdown / testo, in `dataset/mio_corpus/` .

`la riserva`

I tre documenti lunghi Lumen

Già noti da Modulo 2 · Lezione 10–12, in `dataset/riserva_lumen/` — per chi non ha nulla pronto.

Le **fatture Lumen** (`dataset/fatture_lumen/`) sono invece fisse e uguali per tutti: servono solo al blocco di estrazione, indipendente dal corpus scelto per il RAG.



Requisiti minimi e rubrica

Requisito	Criterio
Pipeline end-to-end	Indicizza il corpus, risponde a una query con retrieval reale
Risposta strutturata	Oggetto con `risposta`, `fonti`, `trovato` — coerente col contenuto trovato o no
Estrazione fatture	Campo nullable `None` quando manca, mai inventato

> Niente scheda da compilare oggi: il deliverable è l'app che gira, mostrata nella demo.



Build

TOCCA A VOI

`working/app.py` · 170 minuti

il docente gira tra i banchi
nessun live coding oggi

TODO 1

indicizza_corpus()

load + clean + chunk + embed + index sul vostro corpus.

TODO 2

cerca_chunk(query, k)

Riuso quasi identico di Modulo 2 · Lezione 11.

TODO 3

genera_risposta(query, chunks)

Prompt RAG + structured outputs (Modulo 2 · Lezione 13).

TODO 4

estrai_fattura(path)

Schema `Fattura` di Modulo 2 · Lezione 14, riusato.



Se il vostro corpus non carica

Il pezzo più nuovo di oggi è caricare e pulire file **veri**, non più generati apposta da uno script: è normale che qualche file dia un errore di encoding o un parsing imperfetto.

Se succede: passate alla **riserva Lumen** e tornate al vostro corpus dopo — non restate bloccati sul TODO 1 per tutta la mattina.

> Il docente gira tra i banchi verso metà Build per un giro rapido.



⌨ Demo & valutazione

Ogni studente mostra la propria pipeline

2-3 query sul proprio corpus + estrazione fatture · 45 minuti

`solutions/app.py` a portata del docente per confronto rapido in caso di dubbi durante le demo.



Cosa avete costruito in dodici lezioni

Modulo aikit	Lezione
`loaders`	Modulo 2 · Lezione 4
`clean`	Modulo 2 · Lezione 5
`llm_client`	Modulo 2 · Lezione 3
`embeddings`	Modulo 2 · Lezione 7
`search`	Modulo 2 · Lezione 8
`vectorstore`	Modulo 2 · Lezione 9–10
`chunk`	Modulo 2 · Lezione 10

> Più due pattern riusati oggi senza essere moduli a sé: **structured output** (Modulo 2 · Lezione 13) ed **estrazione** (Modulo 2 · Lezione 14).



Ponte: pausa, poi Modulo 3

Settimana di pausa, poi **Modulo 3** (RAG avanzato) riparte esattamente dalla pipeline costruita oggi: hybrid search, re-ranking, memoria conversazionale, valutazione formale — tutto ciò che oggi era fuori scope diventa il programma del prossimo modulo.



Grazie

